



INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DO PIAUÍ
CAMPUS CORRENTE
TECNOLOGIA EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

GABRIEL ROCHA PAES DA COSTA

**IDENTIFICAÇÃO DE PNEUMONIA EM IMAGENS DE RAIO-X: UMA ABORDAGEM A
PARTIR DO USO DE APRENDIZADO PROFUNDO.**

CORRENTE
2024

GABRIEL ROCHA PAES DA COSTA

IDENTIFICAÇÃO DE PNEUMONIA EM IMAGENS DE RAIO-X: UMA ABORDAGEM A
PARTIR DO USO DE APRENDIZADO PROFUNDO.

Projeto de pesquisa apresentado como exigência para aprovação na disciplina Elaboração De Projeto de Pesquisa do Curso de Tecnologia em Análise e Desenvolvimento de Sistemas do Instituto Federal de Educação, Ciência e Tecnologia do Piauí, Campus Corrente .

Orientador: Prof. Me. Carlos Estevão Bastos Sousa

CORRENTE
2024

GABRIEL ROCHA PAES DA COSTA

IDENTIFICAÇÃO DE PNEUMONIA EM IMAGENS DE RAIOS-X: UMA ABORDAGEM A
PARTIR DO USO DE APRENDIZADO PROFUNDO.

Projeto de pesquisa apresentado como exigência para aprovação na disciplina Elaboração De Projeto de Pesquisa do Curso de Tecnologia em Análise e Desenvolvimento de Sistemas do Instituto Federal de Educação, Ciência e Tecnologia do Piauí, Campus Corrente .

Aprovado em ____/____/____.

BANCA EXAMINADORA:

Prof. Me. Carlos Estevão Bastos Sousa(Orientador)
Instituto Federal do Piauí (IFPI)

Prof. M^e. Felipe Gonçalves dos Santos
Instituto Federal do Piauí (IFPI)

Prof. M^e. Jurandir Cavalcante Lacerda Júnior
Instituto Federal do Piauí (IFPI)

Prof. M^e. Matheus Henrique Borges de Sousa Moraes
Instituto Federal do Piauí (IFPI)

CORRENTE
2024

IDENTIFICAÇÃO DE PNEUMONIA EM IMAGENS DE RAIOS-X: UMA ABORDAGEM A PARTIR DO USO DE APRENDIZADO PROFUNDO.

Nome Completo do(a) Autor(a)¹

Nome Completo do(a) Professor(a) Orientador(a)²

RESUMO

O resumo e o abstract (em inglês) devem ser redigidos em fonte Arial ou Times New Roman, tamanho 12, com espaçamento entre linhas do tipo simples (1,0), contendo no mínimo 150 palavras e, no máximo 250 palavras. Devem estar especificados: os objetivos do trabalho, a fundamentação teórica, a metodologia, os resultados e as conclusões ou considerações. O texto não deve conter citações e siglas. O resumo e o abstract (em inglês) devem ser redigidos em fonte Arial ou Times New Roman, tamanho 12, com espaçamento entre linhas do tipo simples (1,0), contendo no mínimo 150 palavras e, no máximo 250 palavras. Devem estar especificados: os objetivos do trabalho, a fundamentação teórica, a metodologia, os resultados e as conclusões ou considerações. O texto não deve conter citações e siglas. O resumo e o abstract (em inglês) devem ser redigidos em fonte Arial ou Times New Roman, tamanho 12, com espaçamento entre linhas do tipo simples (1,0), contendo no mínimo 150 palavras e, no máximo 250 palavras. Devem estar especificados: os objetivos do trabalho, a fundamentação teórica, a metodologia, os resultados e as conclusões ou considerações. O texto não deve conter citações e siglas. O resumo e o abstract (em inglês) devem ser redigidos em fonte Arial ou Times New Roman, tamanho 12, com espaçamento entre linhas do tipo simples (1,0), contendo no mínimo 150 palavras e, no máximo 250 palavras. Devem estar especificados: os objetivos do trabalho, a fundamentação teórica, a metodologia, os resultados e as conclusões ou considerações. O texto não deve conter citações e siglas. aaaaa

Palavras-chaves: de três a cinco descritores, com iniciais em minúsculo, separadas por ponto e vírgula e finalizada por ponto.

ABSTRACT

Elemento obrigatório, com as mesmas características do resumo em língua vernácula, digitado em folha separada (em inglês Tradução do texto original para o inglês).

Keywords: Tradução das Palavras-chaves para o inglês.

¹ Currículo sucinto do(a) autor(a). Instituição de ensino. E-mail.

² Currículo sucinto do(a) professor(a) orientador(a). Instituição de ensino. E-mail.

Data de Aprovação: ____/____/_____(Data de Apresentação do Artigo)

1 INTRODUÇÃO

A pneumonia é uma infecção respiratória aguda que afeta o parênquima pulmonar e a oxigenação. A doença é bastante comum entre crianças e idosos, sendo uma das principais causas os vírus, bactérias e outros microorganismos que podem induzir a contração. Podendo resultar em problemas pulmonares, o que pode ser fatal se não for diagnosticado desde sua fase inicial (JAISWAL *et al.*, 2019).

Segundo Ibrahim *et al.* (2021), “existem diferentes abordagens para o diagnóstico de pneumonia, algumas destas abordagens incluem radiografia de tórax e tomografia computadorizada”. Entretanto, ao utilizar as imagens geradas pela radiografia ou tomografia para se obter um diagnóstico, o médico precisa ter uma certa experiência e conhecimento para analisar essas imagens, o que pode levar a diversos problemas, como a demora ou um resultado menos preciso.

Deste modo, o médico precisa de experiência e conhecimento para recorrer a um conjunto de informações que tem à sua disposição, de forma a tomar uma decisão adequada. Porém, torna-se difícil determinar um diagnóstico preciso de que os agentes infecciosos presentes nas imagens se tratam da pneumonia, e em mais de 50% dos casos detectados não é possível determinar de qual etiologia se trata. Percebe-se que uma grande parte dos médicos possuem dificuldade em determinar qual agente etiológico ou bacteriano se trata (MAHESSE, 2023). Além disso, com a expansão do número de dados a serem analisados e a complexidade no diagnóstico das imagens, torna-se necessário adotar novas abordagens para melhorar a precisão e a eficiência dos diagnósticos.

Com o avanço da computação, as áreas de Inteligência Artificial (IA) desempenham um papel revolucionário na medicina, especialmente no diagnóstico de diversas doenças (VASILE *et al.*, 2021). O uso de técnicas de *Deep Learning* tem sido amplamente empregado na análise de imagens e previsão de diagnósticos médicos em diversas áreas, como a cardiologia. Dessa forma, foi possível evitar o uso excessivo de ferramentas de alto custo, invasivas ou não invasivas em pacientes que não apresentavam risco de doenças arteriais, o que resultou em uma elevada confiança e resultados comparáveis a outros testes funcionais (BRAGA *et al.*, 2019).

A inclusão de inovações tecnológicas, no campo da medicina, se mostra com resultados precisos e rápidos nos diagnósticos médicos. Dessa forma, soluções que usam de técnicas de aprendizado profundo, entregam resultados rápidos, econômicos e até evitam exames desnecessários para obter os mesmos resultados. Este estudo visa analisar e avaliar o desempenho de diversos algoritmos de deep learning, com foco na detecção de pneumonia em imagens de raio-x do tórax.


2 JUSTIFICATIVA

De acordo com a Organização Mundial da Saúde (OMS), a pneumonia causa morte de aproximadamente 2 milhões de crianças com menos de 5 anos a cada ano e é frequentemente apontada como a principal causa de morte infantil, matando mais crianças do que HIV/AIDS, malária e sarampo juntos. Além disso, os idosos também estão sujeitos à pneumonia, o que pode representar uma grande porcentagem das mortes causadas pela doença. No DATA SUS, no Brasil, foram registradas 44.523 mortes por pneumonia entre janeiro e agosto de 2022. Em comparação com o ano anterior, foram 31.027 óbitos.

Se a pneumonia estiver em um estágio mais avançado, é necessário o envio imediato para o tratamento com antibiótico ou precaução. Assim, o diagnóstico preciso e rápido se torna oportuno e indispensável (SILVA *et al.*,). A radiografia do tórax é indispensável para identificar a pneumonia, mas somente pode ser confirmada por um médico especialista, o que pode resultar em opiniões divergentes, dependendo do profissional. É perceptível que, por se tratar de uma tarefa complexa ou que pode levar a opiniões divergentes, muitas vezes é necessário empregar técnicas de processamento de imagens, muitas vezes combinadas com técnicas de aprendizagem de máquina, para identificá-las (MAHESSE, 2023).

Na Figura 1 observa-se oito radiografias frontais de doenças comuns do tórax, indicadas pelo contorno tracejado vermelho.

Figura 1 – Radiografias frontais de doenças comuns do tórax.



Fonte: Wang *et al.* (2018)

A detecção de pneumonia não é um processo simples, devido à existência de diversos sinais que podem levar a diagnósticos incorretos. Identificar as áreas afetadas é fundamental não apenas para o diagnóstico e tratamento da pneumonia, mas também para o desenvolvimento de novas técnicas de imagem. Os resultados desta pesquisa podem auxiliar na criação de métodos mais eficazes de segmentação de infecções e para uma melhor compreensão das particularidades da doença.

O objetivo deste trabalho é avaliar e comparar os resultados de técnicas de aprendizado de máquina para a análise de radiografias de tórax de pacientes com pneumonia. É crucial que os profissionais de saúde identifiquem com precisão as áreas afetadas em cada paciente para aplicar o tratamento mais adequado e garantir o melhor prognóstico, além de adaptar a estratégia de tratamento conforme necessário.

3 OBJETIVOS

O objetivo deste trabalho é avaliar e comparar a eficiência de classificação e segmentação da região com pneumonia em imagens de radiografias do tórax, utilizando algoritmos de redes neurais convolucionais. O estudo visa avaliar o desempenho de diferentes modelos, além de avaliar a precisão da segmentação de infecção utilizando diversas redes neurais.

3.1. OBJETIVOS ESPECÍFICOS

- Revisar as técnicas atuais de segmentação de imagens médicas, com ênfase na segmentação pulmonar em radiografias do tórax;
- Identificar e selecionar algoritmos de segmentação relevantes, como VGG16 e InceptionV3, implementá-los utilizando o framework de deep learning Keras e treiná-los com um conjunto de dados de radiografias do tórax;
- Adaptar ou criar algoritmos de segmentação para identificar e destacar áreas patológicas associadas à pneumonia nas radiografias e validar a precisão desses modelos comparando-os com diagnósticos médicos existentes;
- Avaliar e ajustar a performance dos modelos de segmentação, incluindo a otimização dos hiperparâmetros e análise da precisão da segmentação;
- Comparar o desempenho dos modelos usando métricas relevantes, analisar os resultados para determinar a melhor performance geral;
- Elaborar um relatório detalhado discutindo as implicações clínicas e práticas, com recomendações para futuras pesquisas ou aplicações clínicas.

4 REFERENCIAL TEÓRICO

Nesta seção serão apresentados os principais conceitos abordados e técnicas fundamentais utilizadas neste trabalho. Inicialmente serão descritos os trabalhos relacionados. Na sequência, falamos da possibilidade de identificação de Pneumonia a partir de imagens de radiografia do tórax. Em seguida, é abordado o tema do aprendizado de máquina, *deep learning* e redes neurais convolucionais, que se aplica à identificação de padrões em imagens.

4.1. TRABALHOS RELACIONADOS

Diversos estudos na literatura abordam o uso de técnicas para detecção de doenças por meio da análise de radiografias torácicas ou tomografias. Com o rápido avanço das tecnologias de aprendizado profundo no campo do processamento de imagens, a aplicação de inteligência artificial e deep learning na detecção de doenças e diagnósticos tornou-se cada vez mais comum na área da saúde.

No estudo de (GUPTA *et al.*, 2021), foi proposto o modelo InstaCovNet-19, uma Rede Neural Convolucional (CNN) baseada em aprendizado profundo. Esse modelo integra três arquiteturas pré-treinadas de CNN, incluindo ResNet-101, Inception v3, Xception, MobileNetv2 e NASNe. Essas arquiteturas são combinadas por meio da técnica de empilhamento integrado, que reúne os recursos para alcançar os resultados mais precisos. O modelo foi aplicado à detecção de três classes: normal, pneumonia e COVID-19, alcançando uma precisão de 99,08

O trabalho de (OLIVEIRA *et al.*, 2021) classifica imagens de radiografia do tórax em duas categorias: COVID-19 e não COVID-19, utilizando um conjunto de imagens de alta qualidade para evitar vieses. Foram usadas 7.875 imagens de COVID-19 e 16.841 de não COVID-19, sendo 6.300 e 13.472, respectivamente, para treinamento e o restante para teste. As imagens foram segmentadas com o modelo U-Net, que atingiu um IoU de 93,33%, antes da classificação por redes neurais convolucionais. Foram utilizados mapas de calor para explicar as classificações, com a média dos mapas de calor dos cinco melhores modelos formando o resultado. Entre os 25 modelos avaliados, VGG-11, ResNet-152, Densenet-161, Densenet-201 e GoogleNet alcançaram acurácia entre 91% e 92%.

A pesquisa de (CHOWDHURY *et al.*, 2020) apresenta um modelo com a base de dados contendo uma mistura de 423 de COVID-19, 1485 de pneumonia viral e 1579 imagens normais de raio-X de tórax. Usando técnicas de aprendizado de transferência e aumento de imagem para treinar o CNN. Foi realizado duas classificações: uma

binária, pneumonia normal e COVID-19 e outra multiclases, pneumonia normal, viral e COVID-19 com e sem data augmentation usando vários modelos pré-treinados.

Em relação ao problema binário sem data augmentation, os modelos ResNet18 e CheXNet obtiveram os mesmos resultados, com uma precisão de 99,41%, sensibilidade de 99,41% e especificidade de 91,41%. Após a aplicação do data augmentation, o modelo DenseNet201 apresentou os melhores resultados, com uma acurácia e sensibilidade de 99,70% e especificidade de 99,55%.

Em relação ao problema de três classes sem data augmentation, o modelo CheXNet apresentou uma acurácia de 97,24%, sensibilidade de 96,61% e especificidade de 98,31%. Com data augmentation, a DenseNet201 atingiu uma acurácia de 97,94%, sensibilidade de 97,94% e especificidade de 98,80%.

No artigo de (BHADRA; KAR, 2020), foi proposta uma arquitetura CNN de múltiplas camadas, menos complexa e com um treinamento significativamente mais rápido em comparação com redes neurais mais avançadas, como MobileNet e ResNet. O estudo utilizou 1.330 casos de COVID-19, 1.330 casos de pneumonia e 1.330 imagens de casos normais, divididos em 80% para treinamento, 10% para validação e 10% para teste cego. O modelo passou por uma verificação cruzada de 10 vezes e obteve uma precisão de 99,1% no teste cego, com um tempo de 114 segundos. Em comparação, as redes pré-treinadas VGG16 alcançaram 93,9% em 549 segundos, a VGG19 obteve 92,2% em 668 segundos, o MobileNet apresentou 98,8% em 224 segundos, o InceptionV3 alcançou 99,5% em 457 segundos e o ResNet50 registrou 98,3% em 537 segundos.

4.2. APRENDIZADO SUPERVISIONADO

O Aprendizado Supervisionado é um paradigma de aprendizagem de máquina para obter as informações de relação de entrada-saída de um sistema com base em um conjunto de amostras de treinamento de entrada-saída pareadas. Dado que a saída é considerada como o rótulo dos dados de entrada ou a supervisão, uma amostra de treinamento de entrada-saída é também chamada de dados de treinamento rotulados ou dados supervisionados (LIU; LIU, 2011).

O objetivo do aprendizado supervisionado é desenvolver um sistema artificial que entenda a relação entre as entradas e saídas, permitindo que ele faça previsões sobre a saída com base em novas entradas.

Um exemplo prático de aprendizado supervisionado é a identificação de pneumonia em radiografias do tórax. O conjunto de dados é formado por imagens rotuladas com a presença ou ausência de pneumonia. O algoritmo é treinado para reconhecer padrões associados à pneumonia e, uma vez treinado, pode detectar a condição em novas imagens.

- 4.3. APRENDIZAGEM DE MÁQUINA (MACHINE LEARNING)
- 4.4. APRENDIZAGEM PROFUNDO (DEEP LEARNING)
- 4.5. REDES NEURAIS CONVOLUCIONAIS (RNCS)
- 4.6. REDES NEURAIS ARTIFICIAIS (RNA)
- 4.7. CLASSIFICAÇÃO DE IMAGENS

5 METODOLOGIA

A pesquisa em questão tem como objetivo avaliar e comparar diferentes algoritmos de redes neurais convolucionais. Para alcançar esse objetivo, adotaremos uma abordagem sistemática que inclui a implementação dos algoritmos e a realização de uma avaliação experimental detalhada.

5.1. REVISÃO DE TÉCNICAS DE SEGMENTAÇÃO

Este trabalho inicia com uma revisão de artigos e estudos recentes sobre técnicas de segmentação de imagens médicas, com ênfase na segmentação pulmonar em radiografias do tórax. A revisão buscará técnicas modernas, incluindo Redes Neurais Convolucionais, VGG16, Inception v3 e outras arquiteturas de deep learning, aplicadas a tarefas de classificação, detecção e segmentação de imagens.

Serão analisados bancos de dados acadêmicos utilizando palavras-chave como "Segmentação de Imagens Médicas", "Radiografias do Tórax", "Segmentação Pulmonar", "Redes Neurais Convolucionais", "Deep Learning em Imagens Médicas", "Modelos de Segmentação", "Avaliação de Algoritmos de Segmentação" e "Diagnóstico de Pneu-
monia em Radiografias".

5.2. SELEÇÃO E IMPLEMENTAÇÃO DE ALGORITMOS

5.3. SELEÇÃO DE ALGORITMOS

5.4. ANÁLISE E RESULTADOS

6 RESULTADOS ESPERADOS

Bla bla bla resultados esperados ...

7 CRONOGRAMA

Nesta seção, apresentamos o cronograma do projeto.

Entregáveis	1º Sem.	2º Sem.	3º Sem.	4º Sem.
Revisão bibliográfica				
Obtenção de especificações				
Modelos em Verilog A/AMS				
Escolha das topologias				
Modelagem matemática				
Projeto dos circuitos CNTFET				
Projeto dos circuitos CNTFET				
Simulações mistas				
Extração de figuras de mérito e Parâmetros S				
Validação em cenários ideal e real				
Análise qualitativa do sistema				
Finalização da dissertação				

Tabela 1 – Cronograma de execução de atividades por semestre.

REFERÊNCIAS

- BHADRA, R.; KAR, S. Covid detection from cxr scans using deep multi-layered cnn. In: IEEE. **2020 IEEE Bombay section signature conference (IBSSC)**. [S.l.], 2020. p. 214–218. Citado na página 10.
- BRAGA, A. V. *et al.* Machine learning: o uso da inteligência artificial na medicina. **Brazilian Journal of Development**, v. 5, n. 9, p. 16407–16413, 2019. Citado na página 5.
- CHOWDHURY, M. E. *et al.* Can ai help in screening viral and covid-19 pneumonia? **IEEE Access**, IEEE, v. 8, p. 132665–132676, 2020. Citado na página 9.
- GUPTA, A. *et al.* Instacovnet-19: A deep learning classification model for the detection of covid-19 patients using chest x-ray. **Applied Soft Computing**, Elsevier, v. 99, p. 106859, 2021. Citado na página 9.
- IBRAHIM, A. U. *et al.* Pneumonia classification using deep learning from chest x-ray images during covid-19. **Cognitive computation**, Springer, p. 1–13, 2021. Citado na página 5.
- JAISWAL, A. K. *et al.* Identifying pneumonia in chest x-rays: A deep learning approach. **Measurement**, Elsevier, v. 145, p. 511–518, 2019. Citado na página 5.
- LIU, B.; LIU, B. Supervised learning. **Web Data Mining: Exploring Hyperlinks, Contents, and Usage Data**, Springer, p. 63–132, 2011. Citado na página 10.
- MAHESSE, G. J. C. Detecção e classificação de pneumonia com base na análise de imagens de radiografia torácica: caso de estudo-hospital central de maputo. Universidade Eduardo Mondlane, 2023. Citado 2 vezes nas páginas 5 e 6.
- OLIVEIRA, B. *et al.* Suporte para diagnóstico de covid-19 por meio de classificação automática de imagens de raio-x e modelos explicáveis. In: Filho, CJAB, Siqueira, HV, Ferreira, DD, Bertol, DW, and ao de Oliveira, RCL, editors, **Anais do 15 Congresso Brasileiro de Inteligência Computacional**. [S.l.: s.n.], 2021. p. 1–8. Citado na página 9.
- SILVA, L. *et al.* Redes neurais convolucionais aplicadas na detecção de pneumonia através de imagens de raio-x. Citado na página 6.
- VASILE, C. M. *et al.* Intelligent diagnosis of thyroid ultrasound imaging using an ensemble of deep learning methods. **Medicina**, MDPI, v. 57, n. 4, p. 395, 2021. Citado na página 5.
- WANG, X. *et al.* **ChestX-ray8 Dataset**. 2018. Citado na página 6.

A RELAÇÃO DE NORMAS TÉCNICAS VIGENTES SOBRE VIDROS PLANOS

Quadro 1: Normas técnicas vigentes sobre Vidros Planos do ABNT/CB-037

Norma
ABNT NBR 16918:2020 Vidro termoendurecido
ABNT NBR 16023:2011 Emenda 1:2020 Vidros revestidos para controle solar - Requisitos, classificação e métodos de ensaio
ABNT NBR 16023:2020 Vidros revestidos para controle solar - Requisitos, classificação e métodos de ensaio

Fonte: Catálogo da ABNT (2022).

AGRADECIMENTOS

Agradeço a todos os professores e servidores do IFPI pois todos Xxxx.

Xxxxxxxxxxxxxxxxxxxxxx, que deu todo o apoio necessário para que chegasse até aqui. Agradeço ao meu Deus, que me deu força quando mais precisava.